

Исследование загрязнений с помощью предсказаний локальной погоды

Чертан Вячеслав Александрович

24 июня 2026 г.

ИИ360 НИУ ВШЭ



4.2 млн

Преждевременных смертей из-за
загрязнения воздуха за год*



5 мкг / м³

Среднегодовая норма содержания PM2.5**



Симуляция

Слишком медленное решение для
оперативного реагирования

* по данным ВОЗ: [https://www.who.int/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)

** по данным ВОЗ: <https://www.who.int/teams/environment-climate-change-and-health/air-quality-and-health/health-impacts/types-of-pollutants>

Постановка задачи

Цель: по динамике концентрации PM2.5 (и полю ветра, где оно есть) определить координаты источника выброса

	Новосибирск	Сахалин
Матрица	251×201	300×300
Ветер (U_{10} , V_{10})	нет	есть
Файлов	49	15
Уникальных источников	10	19

Вход: 17 кадров ($t = 1..17$)

Метка: (x, y) координаты выброса

Метрика: евклидова ошибка локализации в клетках

Подходы к локализации

- Тривиальный бейзлайн
- Физический бейзлайн
- Transolver
- Transolver + heatmap
- Transolver + регрессия
- UNet + heatmap
- Transolver + heatmap + ветер
- PINN


Loss = взвешенная сумма:

- **field** — реконструкция матрицы $C_{t=0}$
- **heatmap** — spatial softmax, матрица вероятностей источника
- **coord** — регрессия (x, y)

$$\mathcal{L} = w_f \mathcal{L}_{\text{field}} + w_h \mathcal{L}_{\text{heat}} + w_c \mathcal{L}_{\text{coord}} + w_p \mathcal{L}_{\text{PDE}}$$

$$\mathcal{L}_{\text{field}} = \frac{\|\hat{C} - C\|_2}{\|C\|_2}, \quad \mathcal{L}_{\text{heat}} = \text{KL}(p_{\text{true}} \| p_{\text{pred}}), \quad \mathcal{L}_{\text{coord}} = \frac{1}{2} \|\hat{x} - x\|_2^2$$


Случайный сдвиг источника



Бейзлайны

Ошибка на тесте:

- без сглаживания — **22.4**
- со сглаживанием — **29.8**




Тривиальный бейзлайн — примеры


хороший: ошибка 3.6 кл



средний: ошибка 17.0 кл




плохой: ошибка 44.9 кл



○ истинный источник × предсказание


Ошибка на тесте:

- без сглаживания — **20.5**
- со сглаживанием — **17.5**




Физический бейзлайн — примеры


хороший: ошибка 5.0 кл



средний: ошибка 13.6 кл



плохой: ошибка 43.7 кл



○ истинный источник × предсказание

Обучаемые модели


Transolver (только поле) — архитектура

Функция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{field}}$$


Ошибка на тесте:

- без сглаживания — **16.2**
- со сглаживанием — **21.0**




Transolver (только поле) — примеры


хороший: ошибка 2.2 кл



средний: ошибка 13.2 кл



плохой: ошибка 29.5 кл




○ истинный источник × предсказание

Функция потерь:


$$\mathcal{L} = \mathcal{L}_{\text{field}} + 0.001 \mathcal{L}_{\text{coord}}$$

Ошибка на тесте: 20.3




Transolver + регрессия — примеры

хороший: ошибка 6.4 кл



средний: ошибка 17.5 кл



плохой: ошибка 42.5 кл



○ истинный источник × предсказание


Transolver + heatmap — архитектура

Функция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}}$$


Ошибка на тесте:

- без сглаживания — **3.6**
- со сглаживанием — **2.1**




Transolver + heatmap — примеры


хороший: ошибка 1.0 кл



средний: ошибка 2.8 кл



плохой: ошибка 5.0 кл



○ истинный источник × предсказание


UNet + heatmap — архитектура

Функция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{heat}}$$


Ошибка на тесте:

- без сглаживания — **1.6**
- со сглаживанием — **1.5**




UNet + heatmap — примеры

хороший: ошибка 0.0 кл



средний: ошибка 1.4 кл



плохой: ошибка 3.0 кл



○ истинный источник × предсказание

Transolver + heatmap + ветер — архитектура


Функция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}}$$

Ошибка на тесте:


- без сглаживания — без ветра **2.6**,
с ветром **5.0**
- со сглаживанием — без ветра **2.5**,
с ветром **2.0**

Разброс между прогонами велик ($n=57$): по среднему различие в пределах шума, со сглаживанием ветер чуть лучше.




Transolver + heatmap + ветер — примеры


хороший: ошибка 1.0 кл



средний: ошибка 2.0 кл



плохой: ошибка 4.1 кл



○ истинный источник × предсказание

$$\mathcal{L}_{\text{PDE}} = \frac{1}{H \cdot W} \|R\|_F^2$$

$$R = (C_{t=1} - \hat{C}_{t=0}) + u \odot \partial_x \hat{C}_{t=0} + v \odot \partial_y \hat{C}_{t=0} - 0.1 \nabla^2 \hat{C}_{t=0}$$

$$\partial_x f_{i,j} = \frac{f_{i+1,j} - f_{i-1,j}}{2}, \quad \partial_y f_{i,j} = \frac{f_{i,j+1} - f_{i,j-1}}{2}$$

$$\nabla^2 f_{i,j} = f_{i+1,j} + f_{i-1,j} + f_{i,j+1} + f_{i,j-1} - 4f_{i,j}$$


Функция потерь:

$$\mathcal{L}_1 = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}} + 0.1 \mathcal{L}_{\text{PDE}}$$

$$\mathcal{L}_2 = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}}$$


Ошибка на тесте:

- без сглаживания — с физ. лоссом **2.6**, без **2.5**
- со сглаживанием — с физ. лоссом **1.6**, без **1.6**




PINN — примеры


хороший: ошибка 1.0 кл



средний: ошибка 2.2 кл



плохой: ошибка 4.1 кл



○ истинный источник × предсказание

Сравнение методов — ошибка локализации (клетки)

Новосибирск ($n = 100$)

Метод	без сгл.	со сгл.
UNet + heatmap	1.6	1.5
Transolver + heatmap	3.6	2.1
Transolver (поле)	16.2	21.0
Transolver + регрессия	20.3	20.3
Trivial	22.4	29.8

Сахалин ($n = 57$)

Метод	без сгл.	со сгл.
PINN	2.6	1.6
Transolver + heatmap (без ветра)	2.6	2.5
Transolver + heatmap (ветер)	5.0	2.0
Trivial	6.6	7.9
Физический	20.5	17.5

- UNet работает лучше, чем Transolver (вероятно, из-за небольшого объема данных)
- Предсказывать матрицу вероятностей лучше, чем делать регрессию координат
- При наличии ветра и меньшем объеме данных, можно получить сопоставимый с большим объемом данных результат

Сравнение методов на тесте

Predictions on test set - nsk

