

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
"НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

ОТЧЕТ ПО ИССЛЕДОВАТЕЛЬСКОЙ ДЕЯТЕЛЬНОСТИ

Исследование загрязнений с помощью предсказаний локальной погоды

Научный руководитель

PhD, заведующий лабораторией,
научно-учебная лаборатория методов анализа
больших данных

Деркач Д. А.
И.О. Фамилия

Студент

Чертан В. А.
И.О. Фамилия

Москва 2026

Введение

Одним из ключевых факторов, влияющих на здоровье людей, является качество воздуха. Особенно опасными для человека являются частицы PM2.5: из-за своего размера (2.5 микрометра и меньше) они могут проникать в легкие, оказывая негативное воздействие на здоровье. По данным Всемирной Организации Здравоохранения, загрязнение атмосферного воздуха стало причиной 4.2 миллиона преждевременных смертей во всем мире в 2019 году [1]. Также, по данным ВОЗ, предельно рекомендуемый уровень PM2.5 составляет $5 \mu g/m^3$ (средний за год) и $15 \mu g/m^3$ (средний за 24 часа) [2]. Чтобы уменьшить объем выброса частиц PM2.5 в атмосферу, необходимо оперативно определять источник выброса и устранять его.

В данный момент оперативная локализация источников загрязнений затруднена из-за неэффективных алгоритмов: в основном используются классические методы, такие как решение систем уравнений и полная симуляция процессов перемещения воздушных масс.

В рамках исследования перемещения загрязнений существует 2 задачи: прямая и обратная.

Прямая задача состоит в следующем: по известным данным об источнике загрязнений и поле ветра определить, куда будут распространяться загрязнения (то есть построить матрицы загрязнений на некоторый период времени). Данную задачу можно решать с помощью математического моделирования, так как она описывается уравнением адвекции-диффузии.

Обратная задача: по известным данным о распространении загрязнений за некоторый период времени (и, возможно, используя данные о поле ветра) определить источник загрязнений. Использовать уравнение адвекции-диффузии становится сложнее, так как для его применения нужно знать, где находится источник, а значит, нужно его перебирать, что сильно увеличивает сложность вычислений. Именно в данную задачу я погружался в этом семестре.

В рамках реализуемого проекта была выдвинута гипотеза, что можно получить высокую точность определения источников выброса частиц с применением современных нейросетевых архитектур.

Данный отчет состоит из трех разделов. В разделе 1 проводится анализ литературы по направлению. Раздел 2 содержит мои продвижения в исследовании, а также результаты экспериментов. В разделе 3 ставятся дальнейшие гипотезы для исследования.

1. Обзор литературы

В рамках предварительного исследования было проанализировано несколько работ из области моделирования загрязнения воздуха.

Предсказание загрязнения в конкретной точке по известным параметрам окружающей среды было реализовано с помощью архитектур ANN (искусственная нейронная сеть), XgBoost (модель градиентного бустинга) и других нейросетевых архитектур и алгоритмов градиентного бустинга [3]. В качестве известных параметров авторы выбрали year (год), month (месяц), day (день), hour (час), PM10, SO2, NO2, CO, O3, TEMP (температура), PRES (давление), DEWP (температура точки росы), rain (выпадение осадков), wd (направление ветра) и WSPM (скорость ветра). По этим параметрам модели обучались предсказывать концентрацию PM2.5 в точке. После проведения тестов оказалось, что XgBoost является лучшей моделью в соотношении затраченного времени к MSE (Mean Squared Error). Авторами был выдвинут тезис, что пользователь больше доверяет модели, прогноз которой может быть объяснен. Поэтому предлагается использовать метод SHAP, который каждому признаку сопоставляет степень его вклада в финальный результат.

Другим способом предсказания концентрации PM2.5 является симуляция перемещения загрязнений, использующая модель вычислительной гидродинамики [4]. Модель вычислительной гидродинамики позволяет анализировать перемещения уже загрязненного воздуха с помощью численного решения уравнений, описывающих газо/гидродинамику потоков. Прогнозирование распространения атмосферных загрязнений с использованием сеточных моделей вычислительной гидродинамики работает по следующей схеме: построение геометрической модели, построение расчетной сетки, настройка модели, моделирование, обработка результатов моделирования.

Задачу предсказания уровня концентрации частиц PM2.5 можно рассматривать как анализ временных рядов, соответственно, архитектура LSTM подходит для предсказания уровня загрязнения [5]. В статье были рассмотрены архитектуры FFNN, RNN, LSTM, ANN с алгоритмом байесовской регуляризации, DL-SSAE (Deep learning stacked sparse autoencoder architecture). Датасет состоял из данных за 58 месяцев со следующими параметрами: Данные состоят из временных рядов температуры (T2(C)), атмосферного давления (Psurf(mm)), относительной влажности (Hum(%)), скорости (W10(m/s на высоте 10 м)) и направления ветра (DIR10(deg на высоте 10 метров)), содержания основных примесей в воздухе (аэрозольные частицы PM2.5 ($\mu\text{g}/\text{m}^3$), озон O3 ($\mu\text{g}/\text{m}^3$), диоксид серы SO2 ($\mu\text{g}/\text{m}^3$), оксиды азота NO2 и NO ($\mu\text{g}/\text{m}^3$), диоксид углерода CO2 (ppm), метан CH4 (ppb)). После проведения экспериментов лучшей оказалась модель, которая предсказывала уровень загрязнения

на следующие 3 часа по данным за прошлые 3 часа.

Для реализации некоторых моделей были разобраны следующие статьи.

Была разобрана Transolver [6] — модификация Transformer для решения задач с пространственными данными, которая уменьшает вычислительную сложность механизма Attention. В данной статье авторы рассматривают применение глубокого обучения для решения дифференциальных уравнений в частных производных (ДУЧП) с помощью архитектуры Transformer. У данной архитектуры есть проблема: обычно для численных методов решения сетка дискретизируется, и на входе у модели оказываются десятки тысяч точек. Механизм Attention вычисляет коэффициент важности для каждой пары точек, поэтому получается сложность, квадратичная относительно входных данных. Выходит, что в такой реализации один проход будет считаться очень медленно. Кроме этого, существует другая проблема: физические взаимодействия достаточно сложные и запутанные, и модели сложно улавливать глобальные закономерности.

Для решения этих проблем в статье предлагается разбить область на M частей, причем для определения принадлежности точки к одной из M частей обучается линейный слой, который преобразует признаки точек в M логитов, и потом применяет Softmax. После этого информация из каждой части агрегируется в новый вектор. И уже на этих M векторах запускается механизм внимания. Далее, для получения результата в каждой точке, обновленные признаки распределяются обратно, используя те же веса, которые использовались при разделении на области.




Рис. 1: Визуализация обучаемых частей в Transolver

Главное преимущество описанного подхода заключается в том, что сложность модели становится линейной относительно числа входных точек N , так как предполагается, что $M \ll N$, и M считается константой. При этом, увеличение значения M только до определенного момента ($M \in \{32, \dots, 64\}$) сильно улучшает качество предсказаний, после чего увеличение времени обучения в сравнении с итоговым качеством становится менее оправданным.

В статье авторы доказывают, что предложенный ими механизм, который они назвали Physics Attention, является аппроксимацией Монте-Карло интегрального оператора на области решения, что теоретически обосновывает его способность решать ДУЧП.

Также авторами были запущены 6 бенчмарков: на упругость, пластичность, обтекание крыла, скорость жидкости в трубе, уравнение Навье-Стокса, моделирование течения жидкости через пористую среду. На всех 6 бенчмарках модель достигла состояния state-of-the-art и в среднем улучшила метрику ошибки на 22%. Модель была запущена на 2 промышленных задачах: Shape-Net Car и AirfRANS, где показала хорошую точность в предсказании коэффициентов сопротивления и подъемной силы.

2. Датасет, аугментации и функции потерь

Для решения задачи компанией CityAir были предоставлены 2 датасета, в одном данные о местности вблизи Новосибирска, в другом данные с Сахалина. Данные представляют из себя матрицу, в каждой точке которой хранится концентрация частиц PM2.5 для этой точки. Для данных с Сахалина дополнительно дана скорость ветра в каждой точке матрицы (размер матрицы такой же, как и у загрязнений).

Сравнительная таблица для датасетов представлена ниже.

	Новосибирск	Сахалин
Матрица	251×201	300×300
Ветер (U10, V10)	нет	есть
Файлов	49	15
Уникальных источников	10	19

В каждом файле содержится $t = 18$ временных кадров. Входными данными будут являться кадры с индексами $1, 2, \dots, 17$ (в 0-индексации). Нулевой кадр будет далее использоваться для обучения предсказания предыдущего шага матрицы загрязнений, так как это может помочь модели лучше уловить физику процесса.

В данной работе используется 2 способа, как модель отдаёт свой прогноз:

1. $(\hat{x}, \hat{y}) \in \mathbb{R}^2$ — предполагаемые координаты источника
2. $Q \in \mathbb{R}^{251 \times 201}$ либо $Q \in \mathbb{R}^{300 \times 300}$, $0 \leq Q_{xy} \leq 1$, $\sum_{x,y} Q_{xy} = 1$ — матрица вероятностей (heatmap) исходного размера.

Если мы хотим получить координату источника из предсказанной матрицы вероятностей Q , то мы будем использовать $(\hat{x}, \hat{y}) = \arg \max Q$. Но такая функция не является непрерывной по Q , потому что возвращает значения только из дискретного множества размера $H \times W$. Для того, чтобы получить функцию оценки близости предсказания, я решил сравнивать матрицы — предсказанную и сгенерированную по координате настоящего источника.

Пусть (x^*, y^*) — координаты настоящего источника. Тогда

$$P_{xy} = \frac{1}{Z} \exp \left(-\frac{(x - x^*)^2 + (y - y^*)^2}{2\sigma_{heat}^2} \right), \quad Z = \sum_{x,y} \exp \left(-\frac{(x - x^*)^2 + (y - y^*)^2}{2\sigma_{heat}^2} \right)$$

Во всех дальнейших моделях $\sigma_{heat} = 4$

Теперь мы имеем 2 матрицы вероятностей: предсказанную Q и действительную P . Про метод их сравнения будет сказано далее в этом разделе.

Можно заметить, что в обоих датасетах уникальных источников не очень много. Если учить модель предсказывать точки $(\hat{x}, \hat{y}) \in \mathbb{R}^2$, а на самом деле точек будет всего 10 или 19 уникальных штук, то она вероятнее всего научится хорошо классифицировать источники и всегда будет выдавать точку, близкую к той, что она видела в обучающих данных. Поэтому было принято решение при обучении каждый раз передаваемую матрицу сдвигать на случайный $\Delta x, \Delta y$, при этом так, чтобы при сдвиге за края матрицы уходила только та область, где концентрация загрязнений равна 0. Это нужно для того, чтобы не сломать физическую подкрепленность данных.

После применения такой аугментации модель будет учить паттерны концентрации загрязнений, а не только проверять, под какой из 10/19 источников данная картина подходит больше всего.




Рис. 2: Пример случайного сдвига

Для обучения моделей используется составная loss-функция, которая выглядит следующим образом:

$$\mathcal{L} = w_f \mathcal{L}_{\text{field}} + w_h \mathcal{L}_{\text{heat}} + w_c \mathcal{L}_{\text{coord}} + w_p \mathcal{L}_{\text{PDE}}$$

Где

$\mathcal{L}_{\text{field}} = \frac{\|\hat{C} - C\|_2}{\|C\|_2}$ — относительная ошибка предсказания 0 кадра матрицы загрязнений

$\mathcal{L}_{\text{heat}} = \text{KL}(P \parallel Q) = \sum_{x,y} P_{xy} \ln \left(\frac{P_{xy}}{Q_{xy}} \right)$ — KL-дивергенция для оценки схожести настоящей матрицы P и предсказанной Q

$\mathcal{L}_{\text{coord}} = \frac{(x - \hat{x})^2 + (y - \hat{y})^2}{2}$ — квадрат расстояния между настоящим и предска-

занным источником

$\mathcal{L}_{\text{PDE}}$ оценивает то, насколько восстановленная матрица $\hat{C}_{t=0}$ подчиняется уравнению адвекции-диффузии (см. раздел «Использование архитектуры PINN»).

Числа $w_f, w_h, w_c, w_p \in \mathbb{R}_{\geq 0}$ — веса, с которыми каждая компонента участвует в итоговой loss-функции. Если какой-то из весов равен 0, то соответствующая функция считаться не будет.

Почти во всех дальнейших методах будет 2 итоговые метрики — среднее расстояние до источника без размытия матрицы и с размытием.

- Если выходом алгоритма является матрица с концентрацией загрязнений, то может случиться такое, что в какой-то из её точек будет запредельная концентрация, тогда как у её соседей не будет выбросов. Так как предсказание по матрице всегда получается как $\arg \max$, то выбросы могут очень сильно ухудшить результат алгоритма. Для того, чтобы их убрать: используется гауссовское размытие.
- Если выход алгоритма — это матрица вероятностей, то для того, чтобы она была более похожа на эталонную матрицу вероятностей, для неё также предлагается применить гауссовское размытие.

Получаем, что в двух разных типах задачи используется одно и то же преобразование для матрицы. Во всех алгоритмах, где применимо, будет использоваться размытие выходной матрицы S с $\sigma_{out} = 2$ по следующей формуле:

$$\tilde{S}_{xy} = \sum_{i,j} S_{ij} G_{\sigma_{out}}(x - i, y - j),$$
$$G_{\sigma_{out}}(\Delta x, \Delta y) = \frac{1}{2\pi\sigma_{out}^2} \exp\left(-\frac{\Delta x^2 + \Delta y^2}{2\sigma_{out}^2}\right)$$

3. Решение обратной задачи

В рамках решения задачи по нахождению источника загрязнений я реализовал несколько архитектур и алгоритмов, основанных на различных нейросетевых архитектурах, подкреплении физикой, а также на проверках предположений и эвристик.

Тривиальный алгоритм

Самое простая, но при этом рабочая идея выглядит так: источником является точка с наибольшей концентрацией загрязнения на последнем кадре. Получаем, что $(\hat{x}, \hat{y}) = \arg \max C_{t=17}$.

Данный метод был запущен и протестирован на датасете Новосибирск. Также было применено гауссовское размытие матрицы перед взятием $\arg \max$, но в данном методе оно только ухудшило предсказание. Итоговые средние евклидовы расстояния от предсказанного источника до настоящего:

- без сглаживания — **22.4**
- со сглаживанием — **29.8**



Рис. 3: Примеры предсказаний тривиального алгоритма

Физический бейзлайн

Поскольку данная задача ранее уже исследовалась в лаборатории, мне было предоставлено базовое решение, в котором с помощью решения уравнения адвекции-диффузии реализована генерация перемещения загрязнений. Проблема заключается в том, что реализованная функция создана для решения прямой задачи: ей на вход даются матрицы с вертикальными и горизонтальными скоростями ветра ($\vec{v}$ и

$\vec{u}$ соответственно), а также матрица C с информацией о концентрации загрязнений. По этим данным функция предсказывает дальнейшее распространение загрязнений $\hat{C} = \mathcal{F}(C, \vec{u}, \vec{v})$. Если мы хотим найти, откуда загрязнение происходит, то, как было сказано во введении, нужно перебрать источник и смоделировать распространение. Но этот подход слишком долгий, поэтому я решил попробовать иной метод: я предположил, что на малом временном промежутке можно пренебречь диффузией, а действие адвекции (то есть движение частиц под действием ветра) развернуть в каждой точке на 180 градусов (то есть $\vec{u}' = -\vec{u}, \vec{v}' = -\vec{v}$). Интуиция была в том, что если $f(x, y, t)$ - это функция перемещения частицы в пространстве, то скорость ветра в данной точке является скоростью частицы $v(x, y, t) = \frac{df(x, y, t)}{dt}$, а тогда на коротком промежутке можно развернуть скорость и получить предыдущее состояние.

После таких преобразований осталось по матрице прошлого состояния найти источник загрязнения. Так как на большой дистанции способ с разворотом ветра работать не будет (частицы будут все дальше распространяться, создавая размытое пятно, а не ожидаемую исходную точку), то много раз делать описанную операцию смысла не имеет. Поэтому нужно научиться распознавать источник загрязнения по области, где эти загрязнения уже успели распространиться.

Так как в реализации этого метода возможности определения источника также, как и в прошлом методе, достаточно ограничены, то лучшее предсказание для источника, которое можно получить — это $(\hat{x}, \hat{y}) = \text{argmax}(\hat{C})$. Метод показал свою работоспособность, но он также, как и предыдущий, не имеет устойчивости к единичным выбросам: если в какой-то одной точке запредельная концентрация выброса, но у ее соседей значение обычное, то метод все равно выберет её источником. Были проведены тесты, средняя ошибка метода составила 20.5. При применении гауссовского размытия, ошибка уменьшилась до 17.5.




Рис. 4: Сравнение предсказаний физического бейзлайна

Как можно видеть на последнем рисунке, разворот ветра и решение уравнения иногда слишком сильно могут откатить распространение, и из-за этого источник будет определен не там, где нужно.

Transolver для предсказания матрицы распространения загрязнений

Вместо попытки симулировать обратный процесс с помощью обратной адвекции можно попробовать научить модель на основе имеющихся данных предсказывать, какое состояние матрицы концентрации загрязнений было в прошлый момент времени. Для проверки гипотезы о том, что применение нейросетевых архитектур уменьшит ошибку предсказания я реализовал несколько моделей, в том числе с использованием архитектуры Transolver. Первое, что хочется проверить, это то, сможет ли Transolver предсказывать матрицу загрязнений так, чтобы прогноз получался лучше, чем у физического бейзлайна. Была выбрана следующая архитектура:




Рис. 5: Архитектура Transolver для предсказания матрицы $\hat{C}_{t=0}$ и локализации источника

Использована компактная конфигурация: 3 блока Transolver, скрытая размерность 64, 4 головы внимания и $M = 64$ части. На вход подаются 17 матриц концентрации $C_{t=1}, \dots, C_{t=17}$, на выходе — предсказанная матрица $\hat{C}_{t=0}$.

Так как в данной модели источник выбирается как $\arg \max$, то есть не дифференцируем, мы можем измерять только различие в матрицах. Тогда функция потерь будет следующей:

$$\mathcal{L} = \mathcal{L}_{\text{field}}$$

Модель обучалась на датасете «Новосибирск» на RTX 4090, 100 эпох с `batch_size = 8`. В результате обучения на тестовой выборке метрики получились следующими:

- без сглаживания — **16.2**
- со сглаживанием — **21.0**

В итоге получаем, что результат действительно стал лучше, чем при самостоятельной попытке симуляции. При этом размытие ухудшило результат, а не улучшило его, в отличие от прошлого метода.



Рис. 6: Сравнение предсказаний с использованием Transolver

Transolver и регрессия координат

Прошлый метод можно улучшить: гипотеза о том, что источник = $\arg \max \hat{C}$ во всех методах не позволяет сделать среднюю ошибку меньше, чем 16 клеток. Поэтому было решено попробовать предсказывать источник по известной матрице распределения с помощью добавления блоков из сверточных и полносвязных слоев так, чтобы на выходе у нас были 2 предполагаемые координаты источника. Для реализации этой идеи была выбрана следующая архитектура:




Рис. 7: Архитектура Transolver + регрессия координат

Так как теперь модели нужно уметь предсказывать не только матрицу, но и итоговые координаты, то функция потерь изменится:

$$\mathcal{L} = \mathcal{L}_{\text{field}} + 0.001 \mathcal{L}_{\text{coord}}$$

Домножение на 0.001 используется, так как относительная ошибка нормируется на исходную матрицу загрязнений, а разность координат при том может быть достаточно большой.

Модель обучалась в таких же условиях, как и прошлая модель Transolver. Средняя ошибка получилась равной 20.3. В этом методе невозможно применить размытие, так как мы получаем на выход только 2 координаты. Как можно заметить,

предсказание не стало лучше, чем у прошлой модели. Предполагаю, что это связано с тем, что у модели регрессии нет никакой информации о взаимосвязи соседних клеток (точнее, она теряется при flatten), а получение достоверного источника через взвешенную сумму нейронов — сложная задача, так как переходит из пространства загрязнения $\mathbb{R}^{H \times W}$, в пространство координат (x, y) .




Рис. 8: Сравнение предсказаний с использованием Transolver и регрессии координат

Transolver и предсказание матрицы вероятностей

Логичным продолжением прошлого метода станет замена регрессии на архитектуру, которая не теряет информацию о взаимосвязи соседей до самого конца и не переходит из одного пространства в другое. Поэтому я решил, что можно предсказывать не 2 координаты, а матрицу вероятностей Q , где Q_{xy} — вероятность того, что источник находится в точке (x, y) . При этом на матрицу наложены условия: $0 \leq Q_{xy} \leq 1$, $\sum_{x,y} Q_{xy} = 1$. Сравнение будет идти с эталонной матрицей источника P , подробнее об этом можно прочитать в разделе «Датасет, аугментации и функции потерь», который был в начале отчета. Для этой идеи была выбрана следующая архитектура:




Рис. 9: Архитектура Transolver + heatmap

В данной модели нужно обучать и предсказание матрицы загрязнений, и предсказание источника. При этом источник достается из матрицы вероятностей. Поэто-

му использовалась следующая функция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}}$$

Модель обучалась в таких же условиях, как и прошлая модель Transolver. В результате среднее расстояние между предсказанным и настоящим источником получилось следующим:

- без сглаживания — **3.6**
- со сглаживанием — **2.1**

Результат стал сильно лучше, чем был при наивном взятии $\arg \max$ от матрицы и при использовании регрессии. Так как единственное изменение — замена регрессии на предсказание вероятности в каждой клетке, то можно заявлять, что гипотеза о том, что регрессия не могла делать хорошие предсказания из-за перехода между пространствами, оказалась правдивой. Кроме того, можно заметить, что при сглаживании результат предсказания сильно улучшается. Это говорит о том, что приведение вероятностного распределения к такому же виду, как и распределение, сгенерированное из координаты источника, улучшает предсказание.



Рис. 10: Сравнение предсказаний с использованием Transolver и предсказания матрицы вероятностей

Unet и предсказание матрицы вероятностей

В прошлой модели сам блок Transolver был узким местом: из-за того, что мы пытались выучить механизм обратного распространения ветра, а потом по этому кадру пытались предсказать расположение источника, информация о следующих 17




Рис. 11: Архитектура UNet + heatmap

кадрах ужималась в нулевой. Можно попробовать не восстанавливать этот кадр, а сразу перейти к поиску источника. Тогда мы получим следующую архитектуру:

Так как в этой модели мы не предсказываем матрицу распространения загрязнений, то функция потерь будет простой:

$$\mathcal{L} = \mathcal{L}_{\text{heat}}$$

В результате обучения удалось достичь следующего среднего расстояния между источником и предсказанием:

- без сглаживания — **1.6**
- со сглаживанием — **1.5**

То есть результат стал действительно лучше, чем в модели с Transolver. Тем не менее, в то время как от прошлых архитектур можно было убрать Transolver и подать на вход только один кадр, получив хорошее предсказание, тут точно понадобятся все 17 кадров.



Рис. 12: Предсказания с использованием Unet и предсказания матрицы вероятностей

Проверка значимости ветра

Как упоминалось ранее, в датасете «Сахалин» кроме матрицы с концентрацией загрязнений также есть информация о вертикальной и горизонтальной скорости ветра в каждой точке. Соответственно, возникает вопрос: улучшатся ли предсказания матрицы загрязнений и координат источника, если вместе с матрицей загрязнения на шагах $t = 1, \dots, 17$ передавать еще и матрицы вертикальной и горизонтальной скорости ветра для тех же t .

Для проверки было обучено 2 модели: первая (без ветра) аналогична модели из раздела «Transolver и предсказание матрицы вероятностей», вторая — похожая, но с измененным размером входных данных, они увеличены в 3 раза, туда добавлены по 2 матрицы ветра для каждого из 17 входных кадров:




Рис. 13: Архитектура Transolver + heatmap + wind

Функция потерь также была выбрана аналогично функции для такой же модели ранее:

$$\mathcal{L} = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}}$$

В данном эксперименте важными являются 2 вопроса: стало ли предсказание источника лучше, и стало ли лучше предсказание матрицы загрязнений?

Обе модели обучались в идентичных условиях: RTX 4090, 100 эпох, batch_size=4. Также для предсказания источника было применено сглаживание матрицы вероятностей. В результате были получены следующие метрики:

Для модели с информацией о ветре:

- Среднее расстояние от предсказанного до настоящего источника без сглаживания: 5.0
- Среднее расстояние от предсказанного до настоящего источника со сглаживанием: 2.0
- $\mathcal{L}_{\text{field}} = 1.01$ (относительная ошибка предсказания матрицы)

Для модели без информации о ветре:

- Среднее расстояние от предсказанного до настоящего источника без сглаживания: 2.6
- Среднее расстояние от предсказанного до настоящего источника со сглаживанием: 2.5
- $\mathcal{L}_{\text{field}} = 0.87$

Однозначного улучшения от ветра нет: по несглаженной ошибке локализации и по качеству восстановления матрицы ($\mathcal{L}_{\text{field}}$: 1.01 против 0.87) модель с ветром даже немного хуже, а со сглаживанием — наоборот, чуть лучше (2.0 против 2.5). Но разброс между прогонами велик ($n = 57$, один сид), поэтому различие в пределах шума, и уверенно говорить о пользе ветра нельзя. Вероятно, это связано с тем, что модель с ветром получается сильно больше по размеру, при этом информация о скорости восстанавливается из поведения частиц загрязнений между шагами, за счет чего мы только усложняем архитектуру, давая модели больше степеней свободы, за счет чего ей становится труднее найти лучшее решение задачи восстановления матрицы. А так как источник определяется именно по этой матрице, заметного выигрыша по локализации ветер не даёт.




Рис. 14: Предсказания с использованием Transolver + heatmap с информацией о ветре

Использование архитектуры PINN

Для того, чтобы улучшить модель UNet для предсказания источника, можно попробовать сделать так, чтобы она в своих действиях подчинялась законам физики. Распространение загрязнений под действием ветра подчиняется уравнению адвекции-диффузии. Из-за этого появилась идея: можно штрафовать модель за то, что прогнозы матрицы загрязнений, которые она отдает, не подчиняются данному закону. Определим компоненту функции потерь:

$$\mathcal{L}_{\text{PDE}} = \frac{1}{H \cdot W} \|R\|_F^2$$

$$R = (C_{t=1} - \hat{C}_{t=0}) + u \odot \partial_x \hat{C}_{t=0} + v \odot \partial_y \hat{C}_{t=0} - 0.1 \nabla^2 \hat{C}_{t=0}$$

$$\partial_x f_{i,j} = \frac{f_{i+1,j} - f_{i-1,j}}{2}, \quad \partial_y f_{i,j} = \frac{f_{i,j+1} - f_{i,j-1}}{2}$$

$$\nabla^2 f_{i,j} = f_{i+1,j} + f_{i-1,j} + f_{i,j+1} + f_{i,j-1} - 4f_{i,j}$$

$\odot$ — адамарово произведение: $(A \odot B)_{ij} = A_{ij} \cdot B_{ij}$

∂_x, ∂_y — численные приближения частных производных

∇^2 — численное приближение Лапласиана

Получается, что чем больше квадрат нормы невязки, которая получена из уравнения адвекции-диффузии, тем больше мы штрафует модель.

Для обучения была выбрана следующая архитектура: свёрточная сеть + 2 отдельные головы, одна из них предсказывает матрицу загрязнений ($\hat{C}_{t=0}$), а другая — матрицу вероятностей (источник берётся как $\arg \max$).




Рис. 15: Архитектура PINN: свёрточная сеть с двумя головами (матрица загрязнений и матрица вероятностей)

Для проверки значимости использования физического loss было обучено 2 идентичные модели с разными функциями потерь:

$$\mathcal{L}_1 = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}} + 0.1 \mathcal{L}_{\text{PDE}}$$

$$\mathcal{L}_2 = \mathcal{L}_{\text{field}} + \mathcal{L}_{\text{heat}}$$

В результате обучения для модели с $\mathcal{L}_{\text{PDE}}$ были получены следующие метрики:

- Среднее расстояние от предсказанного до настоящего источника без сглаживания: 2.6

- Среднее расстояние от предсказанного до настоящего источника со сглаживанием: 1.6
- $\mathcal{L}_{\text{field}} = 0.42$

Для модели без $\mathcal{L}_{\text{PDE}}$:

- Среднее расстояние от предсказанного до настоящего источника без сглаживания: 2.5
- Среднее расстояние от предсказанного до настоящего источника со сглаживанием: 1.6
- $\mathcal{L}_{\text{field}} = 0.42$

Получается, что добавление штрафа за несоответствие физике не влияет на сходимость обучения, результаты и с ним, и без него получаются почти идентичными. Тем не менее, стоит заметить, что такая простая модель получает сильно более низкую ошибку предсказания поля, чем Transolver с/без ветра.




Рис. 16: Предсказания с использованием сверточной сети

4. Заключение

В таблицах 1 и 2 сведены итоговые результаты всех рассмотренных методов на двух датасетах. В качестве метрики приведена средняя по тестовой выборке ошибка локализации источника (в клетках) — евклидово расстояние между предсказанной и истинной позицией источника, — без сглаживания и со сглаживанием выходной матрицы перед взятием $\arg \max$ (для регрессии координат сглаживание неприменимо). Полужирным выделен лучший метод на каждом датасете.

Таблица 1: Ошибка локализации источника (в клетках), Новосибирск ($n = 100$)

Метод	без сглаживания	со сглаживанием
UNet + heatmap	1.6	1.5
Transolver + heatmap	3.6	2.1
Transolver (поле)	16.2	21.0
Transolver + регрессия	20.3	20.3
Trivial	22.4	29.8

Таблица 2: Ошибка локализации источника (в клетках), Сахалин ($n = 57$)

Метод	без сглаживания	со сглаживанием
PINN	2.6	1.6
Transolver + heatmap (без ветра)	2.6	2.5
Transolver + heatmap (ветер)	5.0	2.0
Trivial	6.6	7.9
Физический	20.5	17.5

Из сравнения можно сделать следующие выводы:

1. UNet + heatmap уверенно превосходит подходы на основе Transolver на данных Новосибирска; вероятно, на сравнительно небольшом объёме данных более простая свёрточная архитектура обучается устойчивее.
2. Предсказание матрицы вероятностей (heatmap) даёт существенно меньшую ошибку, чем прямая регрессия координат источника.
3. На данных Сахалина добавление поля ветра не даёт однозначного улучшения: разница между моделями с ветром и без него лежит в пределах разброса между прогнозами ($n = 57$, один сид).

Список литературы

1. *World Health Organization*. Ambient (outdoor) air pollution – Key facts. — 2024. — Fact sheet, 24 October 2024. [https://www.who.int/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health).
2. *World Health Organization*. Air quality, energy and health. — 2021. — Guideline table, released 22 September 2021. <https://www.who.int/teams/environment-climate-change-and-health/air-quality-and-health/health-impacts/types-of-pollutants>.
3. Ци Д., Буре В. М. Исследование методов прогнозирования временных рядов для предсказания качества воздуха: объяснительный сравнительный анализ // Вестник Санкт-Петербургского университета. Прикладная математика. Информатика. Процессы управления. — 2024. — Т. 20, № 2. — С. 206–219. — DOI: 10.21638/spbu10.2024.206.
4. Пожаркова И. Н., Гапоненко А. В., Сергеев И. Ю. Автоматизация решения задачи прогнозирования распространения атмосферных загрязнений с учетом окружающего ландшафта и застройки // Сибирский пожарно-спасательный вестник. — 2023. — Т. 28, № 1. — С. 8–15. — DOI: 10.34987/vestnik.sibpsa.2023.74.74.013.
5. Дель И. В., Старченко А. В. Использование методов нейросетевого моделирования для прогнозирования качества атмосферного воздуха // Вестник Томского государственного университета. Управление, вычислительная техника и информатика. — 2023. — № 65. — С. 15–24. — DOI: 10.17223/19988605/65/2.
6. Transolver: A Fast Transformer Solver for PDEs on General Geometries / H. Wu [и др.]. — 2024. — arXiv: 2402.02366 [cs.LG]. — URL: <https://arxiv.org/abs/2402.02366>.